


מבוא למדעי הנתונים - הערכה חלופית:

תהליך העבודה המתואר מבוסס נתונים שנלקחו מתוך "קאגל"-
<https://www.kaggle.com/datasets/datasnaek/chess> "הדאטה סאט" מכיל 20,058 משחקי שחמט.
עמודת שם הפתיחה עברה עיבוד מקדים ב-"פייתון" כך שתציג כ-130 ערכים במקום כ-1500 שהיו ב-"דאטה סאט" המקורי דבר המאפשר ניתוח סטטיסטי ממוקד המתאים יותר לסיווג קטגוריאלי. כמו כן עמודת " opening eco" עודכנה כך שתכיל רק 5 קטגוריות בלבד.

20058 instances
11 features (8.2% missing values)
Data has no target variable.
9 meta attributes

Columns (Double click to edit)	Name	Type	Role	Values
1	rated	categorical	feature	False, True
2	created_at	numeric	skip	
3	last_move_at	numeric	skip	
4	turns	numeric	feature	
5	victory_status	categorical	feature	draw, mate, outoftime, resign
6	winner	categorical	feature	black, draw, white
7	white_rating	numeric	feature	
8	black_rating	numeric	feature	
9	opening_ply	numeric	feature	
10	line_number	numeric	skip	
11	eco_category	categorical	feature	A, B, C, D, E
12	id	text	skip	
13	increment_...	text	skip	
14	white_id	text	skip	
15	black_id	text	skip	



בשלב הראשון נעשה עיבוד בטבלת המשתנים כך שחלק מהעמודות סומנו כ-skip (למשל מזהים טכניים וחותרות זמן), מאחר שאין להן תרומה ישירה לחיזוי ונועדו רק לתיעוד. עמודות אחרות הוגדרו כ-feature ומשמשות כקלט למודל, ובהן מאפייני המשחק המרכזיים (כמו מספר המסעים, דירוגי השחקנים ותוצאת המשחק) לצד משתני הפתיחה המעובדים.

בתרשים הזרימה מוצג תהליך העיבוד שנבנה בסביבה הוויזואלית. הנתונים נטענים מקובץ, עוברים סינון של עמודות רלוונטיות, ולאחר מכן צמצום מספר ערכי הפתיחה כך שפתיחות נדירות מאוחדות לקטגוריית (other) (other), כמו כן הוספת עמודה חדשה המחושבת על-פי ההפרש המוחלט בין דירוג הלבן לדירוג השחור. לאחר האיחוד של המסלולים מתקבלת טבלת עבודה מרוכזת, עם סט מצומצם ומובחן של מאפיינים שימשו בשלבים הבאים של הניתוח והמידול.

Info
20058 instances (no missing data)
9 features
Target with 4 values
No meta attributes.

Variables
☒ Show variable labels (if present)
☒ Visualize numeric values
☒ Color by instance classes


Selection
☒ Select full rows

	victory_status	rated	turns	winner	opening_ply	eco_category	white_rating	black_rating	elo_dif	main_opening
1	outoftime	False	13	white	5	D	1500	1191	309	Slav Defense
2	resign	True	16	black	4	B	1322	1261	61	Nimzowitsch...
3	mate	True	61	white	3	C	1496	1500	4	King's Pawn ...
4	mate	True	61	white	3	D	1439	1454	15	Queen's Pa...
5	mate	True	95	white	5	C	1523	1469	54	Philidor Defe...
6	draw	False	5	draw	4	B	1250	1002	248	Sicilian Defe...
7	resign	True	33	white	10	D	1520	1423	97	Blackmar-Di...
8	resign	False	9	black	5	B	1413	2108	695	Nimzowitsch...
9	resign	True	66	black	6	C	1439	1392	47	Italian Game
10	mate	True	119	white	4	B	1381	1209	172	Scandinavia...
11	mate	False	39	white	1	A	1381	1272	109	Van't Kruijs ...



בסיום שלב העיבוד התקבל מערך נתונים נקי הכולל 20,058 רשומות ללא ערכים חסרים. הדאטה ממוקד בתשעה מאפיינים נבחרים וכולל משתנה מטרה -סטטוס המנצח בעל ארבעה ערכים. בהמשך לתהליך בוצע שלב של ויזואליזציה שמטרתו להמחיש את הקשרים הסטטיסטיים במערך המידע. נעשה שימוש בגרף פיזור לבחינת היחסים בין משתנים כמותיים, לצד התפלגויות, המאפשרת לזהות מגמות מרכזיות או חריגים בנתונים. לתיקוף הממצא הוויזואלי, חושבו מדדי מרכז ופיזור, תוך כדי התייחסות לתוצאות שהתקבלו.

הגרף מציג את התפלגות תוצאות המשחקים בהתבסס על הדירוג, הצבעים בגרף מסווגים את התוצאות: כחול לניצחון של שחור, ירוק ללבן, ואדום לתיקו כאשר התיקו מתרכז בבירור לאורך קו השוויון בין הדירוגים. ניתן לראות כי הנקודות מתרכזות סביב האלכסון המרכזי, מה שמעיד על כך שרוב המשחקים נערכים בין יריבים בעלי רמת מיומנות דומה. אם כי ניתן לראות כי קיימת הטיית ניצחון לשחור דבר שמנוגד ל-"תיאוריה בשחמט" הגורסת כי יש יתרון ללבן בזכות המהלך הראשון.



הטבלה מציגה ניתוח המתאם בין המשתנים, התקבל קשר חיובי של 0.63 בין דירוג השחקן הלבן לדירוג השחקן השחור. מתאם זה מעיד על זיקה ישירה בין רמות המתמודדים, כפי שמשתקף גם בגרפי הפיזור המראים ריכוז נתונים סביב הקו האלכסוני. ניתן לזהות עקביות בנתונים שעשויים לייצג את טיב הדאטה והשימוש בו. שאר המתאמים חלשים עד בינוניים, ולכן אין קשרים לינאריים חזקים נוספים בין רוב המשתנים הרציפים.


Pearson correlation

(All combinations)

Filter ...

1	+0.634	black_rating : white_rating
2	+0.277	opening_ply : white_rating
3	+0.255	black_rating : opening_ply
4	+0.160	black_rating : turns
5	+0.130	turns : white_rating
6	-0.127	elo_dif : turns
7	+0.073	elo_dif : white_rating
8	+0.056	opening_ply : turns
9	+0.025	black_rating : elo_dif
10	-0.017	elo_dif : opening_ply


שתי ההיסטוגרמות מציגות התפלגות כמעט נורמאלית של דירוגי הלבן והשחור עם ממוצע דירוג של כ-1600 עם סטיית תקן של 291. הדמיון הצורה והמיקום עשויים להעיד על כך שרמת המשחק של השחקנים שווה במדגם.



הטבלה הסטטיסטית חושפת כי המאגר נקי מערכים חסרים ומציגה התפלגות דירוגים שבה הממוצע לשני הצדדים נע סביב 1590 בעוד שהערך השכיח הוא 1500 מה שמעיד על נקודת פתיחה סטנדרטית במערכת הדירוג. בניגוד לרושם הוויזואלי מגרף הפיזור המשתנה השכיח במנצחים הוא דווקא הלבן נתון התואם את תיאוריית השחמט הקלאסית ומצביע על דאטה תקין מבחינה לוגית. רוב המשחקים מסתיימים כניעה. כאשר הפתיחה הדומיננטית ביותר היא ההגנה הסיציליאנית.

Name	Distribution	Mean	Mode	Median	Dispersion	Min	Max	Missing
turns		63.47	63	55	0.58	1	349	0 (0 %)
opening_ply		4.82	3	4	0.58	1	28	0 (0 %)
white_rating		1596.63	1500	1567	0.18	784	2700	0 (0 %)
black_rating		1588.63	1500	1562	0.18	789	2723	0 (0 %)
elo_dif		173.061	0.00	115	1.03535	0.00	1605	0 (0 %)
rated					0.493			0 (0 %)
winner					0.85			0 (0 %)
eco_category				C	1.4			0 (0 %)
main_opening				Sicilian Defense	3.64			0 (0 %)
victory_status				resign	1.04			0 (0 %)

draw resign




Neural Network
Name
Neural Network
Neurons in hidden layers:
200,100,50,20
Activation:
ReLU
Solver:
Adam
Regularization, $\alpha=0.01$:
Maximal number of iterations:
500
Replicable training
Cancel
Apply Automatically

במטרה לשפר את איכות החיזוי ולקבל תוצאות משמעותיות, בוצע סינון של מערך הנתונים ל-5,649 רשומות בלבד תוך הכללת משחקים מדורגים בלבד הסרת משחקים שנגמרו בזמן והתמקדות במשחקים בעלי 10 מהלכים לפחות. הקריטריון המשמעותי ביותר היה הגבלת הפרש הדירוג לפחות מ-100 נקודות. בחירות אלו מאפשרות לבחון את יכולת המודל לנבא הכרעה בין יריבים שקולים. כמו כן המודל אומן על 80% מהדאטה. לצורך המידול נבנתה רשת עצבית בעלת מבנה "משפך" של ארבע שכבות.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	0.680	0.640	0.638	0.636	0.640	0.289

		Predicted				
		draw	mate	outoftime	resign	Σ
Actual	draw	100.0 %	0.1 %	NA	0.1 %	308
	mate	0.0 %	46.0 %	NA	29.9 %	1890
	outoftime	0.0 %	0.0 %	NA	0.0 %	0
	resign	0.0 %	53.9 %	NA	70.0 %	3451
Σ		303	1801	0	3545	5649

למרות המורכבות המבנית והעלאת מספר האיטרציות ל-500 המודל הגיע לדיוק של 0.64 בלבד, ממטריצת הבלבול עולה כי המודל מצליח לזהות תוצאות תיקו בדיוק גבוה (100%), אך מתקשה מאוד להבחין בין ניצחון ב-"מט" לבין "כניעה". ניתן לראות כי 53.9% מהמשחקים שהסתיימו בכניעה סווגו בטעות ככאלו שהסתיימו במט, ו-29.9% מהמשחקים שהסתיימו במט סווגו כפרישה. בלבול זה מובן, שכן שני סוגי הסיום מייצגים ניצחון מוחלט.



Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	2615....	51.142	42.455	0.027	0.961

Model	MSE	RMSE	MAE	MAPE	R2
Neural Network	3700....	60.835	45.300	0.029	0.944

בשלב זה בוצע ניבוי של המשתנה הרציף (דירוג השחקן הלבן) כמשתנה יעד. נערכה השוואה בין מודל רגרסיה ליניארית לבין רשת עצבית עמוקה כאשר הערכת המודלים התבססה על שיטת Cross Validation.

התוצאות מצביעות על דיוק גבוה במיוחד: מדד R^2 הגיע ל-0.961 ברגרסיה הליניארית ול-0.944 ברשת העצבית, נתון המעיד כי המודלים מסבירים מעל 94% מהשונות בנתונים. מדד ה-RMSE הטעות הממוצעת נע בין 51 ל-60 נקודות.

עבודה זו בחנה מערך נתונים הכולל 20,058 משחקי שחמט במטרה לחזות תוצאות משחקים ודירוגי שחקנים. בשלבי הניתוח הראשוניים נמצאה עקביות סטטיסטית גבוהה בדאטה, עם התפלגות נורמלית של דירוגי השחקנים סביב ממוצע של כ-1600 ומתאם חיובי (0.63) בין רמות המתמודדים. תצפיות אלו איששו כי המדגם מייצג נאמנה משחקים בין שחקנים שקולים.

שלב הסיווג התמקד בחיזוי תוצאת המשחק בקרב יריבים שקולים (הפרש דירוג קטן מ-100). רשת הנוירונים הציגה ביצועים מתונים עם AUC של 0.68 ודיוק (CA) של 64%. ממטריצת הבלבול עלה כי המודל מתקשה להבחין בין סוגי הכרעה דומים (מט מול כניעה), בעוד שהוא מזהה תוצאות תיקו בדיוק מוחלט.

בשלב הרגרסיה המודל חזה את דירוג השחקן הלבן. כאן התקבלו תוצאות מעולות עם מדד R^2 של 0.961 ברגרסיה הליניארית וטעות ממוצעת (RMSE) של כ-51 נקודות בלבד. למרות הדיוק הגבוה, יש לציין שהתוצאה נובעת בעקבות סינון הפרשי הדירוג, ולא בהכרח מיכולת הכללה עמוקה של המודל.

במבט בוחן על איכות הנתונים, ניתן לזהות מספר גורמים שהשפיעו על תקרת ביצועי המודל. ראשית, המתאם בין דירוגי השחקנים עומד על -0.63 ערך המעיד על קשר חיובי טוב, אך לא מעולה. בנוסף, קיומו של ערך ברירת מחדל בדירוג 1500 יצר עיוות סטטיסטי מסוים, מכון שהוא מייצג שחקנים חדשים שרמתם האמיתית טרם נקבעה לצד שחקנים ותיקים. אלו בלבד מעלות סימני שאלה אודות איכות הנתונים.

כמוכן, על אף ש-20,000 רשומות נראות ככמות נתונים משמעותית, בעולם השחמט המכיל אינספור וריאציות של פתיחות ומהלכים, מדגם זה יחסית מצומצם ועלול להוביל להטיה וחוסר דיוק. לא זאת בלבד אלא הצמצום הנוסף של הדאטה לצרכי סינון השאיר מודל שהתאמן על כ-5,600 משחקים בלבד, מה שמחליש את התוקף הסטטיסטי של הממצאים ומונע מהרשת העצבית למצות את פוטנציאל הלמידה העמוקה שלה באזורים המורכבים של המשחק.

לסיכום, העבודה מדגימה את הפוטנציאל לצד המגבלות של יישום למידת מכונה בניתוח משחקי שחמט. נמצא כי ניתן לחזות משתנים מספריים בדיוק גבוה יחסית, אך חיזוי אופן ההכרעה בין יריבים שקולים נותר אתגר מורכב. הממצאים מדגישים את חשיבות איכות והיקף הנתונים בתקרת הביצועים של המודלים.